

# Notebook 1: Preparación de Datos

## ¿Qué hace este notebook?

Este notebook organiza las imágenes del dataset **Animals5** en carpetas separadas para:

- **Entrenamiento** (train): Las imágenes que el modelo usará para aprender
- **Validación** (val): Imágenes para verificar el progreso durante el entrenamiento
- **Prueba** (test): Imágenes nuevas para evaluar el rendimiento final

## ¿Por qué es importante?

Separar los datos evita que el modelo "haga trampa" memorizando las imágenes de prueba. Así podemos medir qué tan bien generaliza a imágenes que nunca ha visto.

## Distribución de datos

- Cada categoría tiene **1,446 imágenes** (balanceado)
- Train: 723 | Validación: 361 | Test: 362 por clase

```
import os
import shutil
import random

# Configuración
SOURCE_DIR = 'Animals5'
BASE_DIR = 'dataset_split'
CATEGORIES = ['cavallo', 'elefante', 'gallina', 'mucca', 'pecora']
# El conteo mínimo encontrado fue 1446 (elefante), limitamos todas las
# clases a este número para simetría.
TARGET_COUNT = 1446

TRAIN_SPLIT = 0.5
VAL_SPLIT = 0.25
TEST_SPLIT = 0.25

def prepare_data():
    # Limpiar directorio de destino si existe
    if os.path.exists(BASE_DIR):
        shutil.rmtree(BASE_DIR)

    for category in CATEGORIES:
        print(f"Procesando {category}...")

        # Ruta fuente
        src_path = os.path.join(SOURCE_DIR, category)
```

```

    all_files = [f for f in os.listdir(src_path) if
f.lower().endswith(('.png', '.jpg', '.jpeg'))]

    # Aleatorizar
    random.shuffle(all_files)

    # Truncar al conteo objetivo
    selected_files = all_files[:TARGET_COUNT]
    print(f" Seleccionadas {len(selected_files)} imágenes de
{len(all_files)}")

    # Calcular índices de división
    n_train = int(TARGET_COUNT * TRAIN_SPLIT) # 723
    n_val = int(TARGET_COUNT * VAL_SPLIT) # 361
    # Test toma el resto para asegurar que el total coincida

    train_files = selected_files[:n_train]
    val_files = selected_files[n_train:n_train+n_val]
    test_files = selected_files[n_train+n_val:]

    # Crear directorios y copiar
    for subset, files in [('train', train_files), ('val',
val_files), ('test', test_files)]:
        dest_dir = os.path.join(BASE_DIR, subset, category)
        os.makedirs(dest_dir, exist_ok=True)

        for f in files:
            shutil.copy2(os.path.join(src_path, f),
os.path.join(dest_dir, f))

    print(f" Split: Train={len(train_files)},
Val={len(val_files)}, Test={len(test_files)}")
prepare_data()

```